


UNIVERSITÉ PROTESTANTE AU CONGO
FACULTÉ DES SCIENCES INFORMATIQUES

B.P. 4745 KINSHASA 2

L2 LMD



Monographie Projet

*Conception et implémentation d'une plateforme intelligente d'aide au diagnostic du
cancer du poumon par réseau de neurones convolutif (CNN)*

Par

NKASHAMA MWAMBA Raddai

Directeur : Assistant Vacar

Année académique 2025–2026

« Si l'intelligence était un gâteau, l'apprentissage non supervisé en serait la pâte, l'apprentissage supervisé le glaçage, et l'apprentissage par renforcement la cerise posée au sommet. »

— Yann LeCun, pionnier des réseaux de neurones convolutifs

REMERCIEMENTS

Avant toute chose, nous rendons grâce à Dieu Tout-Puissant, Créateur de toute chose, source de toute sagesse et de toute intelligence, qui nous a accordé le souffle, la santé, la force et la persévérance nécessaires pour mener ce travail à son terme. Sans Sa grâce, rien de tout cela n'aurait été possible.

Nous adressons ensuite notre profonde et respectueuse gratitude à notre Directeur l'assistant Vacar , pour sa disponibilité, son encadrement, la justesse de ses conseils, qui ont donné à ce travail toute la profondeur scientifique qu'il devait avoir. Notre reconnaissance s'étend à tout le corps professoral et à l'ensemble du personnel académique de la Faculté des Sciences Informatiques de l'Université Protestante au Congo.

Nos pensées les plus tendres et les plus sincères vont à nos parents TSHIDIBI Willy et NDENGÉJA Archibelle, à qui nous devons tout : leur amour inconditionnel, leurs sacrifices silencieux et leur foi inébranlable en notre réussite ont été le socle sur lequel s'est bâti chacun de nos accomplissements. Que ce travail soit pour eux une modeste récompense de tant d'efforts consentis en notre faveur.

Nous remercions chaleureusement MWAMBA Obrayanne, MWAMBA Bigvaï, MWAMBA Yves et KABONGO Jupsi, NGOYA Blandine et Ntumba Prisca, pour leurs présence constante et réconfortante, dont la joie et l'innocence ont souvent été, dans les moments de doute, une source inattendue de motivation et de douceur.

Une pensée toute particulière est adressée à nos ami(e)s MUAMB Obed, KABASELE Exaucé, MUNDAYI Jonathan, KAZADI Yedidiah et NGOY Ben, KAYEMBE Michée, MBONDO et Ruth, KANDE Jeannette, complices fidèles des heures de doute comme des heures de joie, qui ont su, chacun à sa manière, alléger le poids de ce parcours par leur écoute, leurs encouragements et leur amitié sincère.

Enfin, nous exprimons notre profonde gratitude à l'ensemble de nos collègues de la promotion de Licence 2, compagnons de cette aventure académique, avec qui furent partagés les efforts, les nuits de révision, les inquiétudes et les fous rires : que chacun trouve ici le témoignage de notre estime et de notre amitié fraternelle.

À toutes celles et à tous ceux qui, d'une façon ou d'une autre, ont contribué à l'aboutissement de ce travail, nous disons, du fond du cœur, merci.

RÉSUMÉ

Le cancer du poumon demeure l'une des principales causes de mortalité par cancer dans le monde, et son pronostic dépend étroitement de la précocité du diagnostic. La présente monographie décrit la conception et l'implémentation de PulmoCare IA, une plateforme d'aide au diagnostic destinée aux professionnels de santé, combinant un module d'intelligence artificielle fondé sur un réseau de neurones convolutif (CNN), un back-end orienté objet développé en PHP, et une interface web pensée pour un usage médical professionnel. Le système analyse des images de scanner thoracique (CT Scan) et les classe en trois catégories cliniques : normal, bénin et malin, avant d'enrichir ce résultat brut d'informations diagnostiques complémentaires telles que le stade TNM estimé, le type histologique probable et des recommandations cliniques. La démarche méthodologique a consisté à fusionner deux jeux de données complémentaires afin de pallier l'absence de cas non cancéreux dans le corpus initial, à concevoir une architecture CNN modulaire et paramétrable, puis à l'entraîner en tenant compte du déséquilibre des classes par pondération automatique. Le modèle obtenu atteint une exactitude globale de 95,83 pour cent et une sensibilité de 98,78 pour cent sur la classe maligne, avec une aire sous la courbe ROC macro de 0,974, satisfaisant ainsi le seuil de sensibilité médicale usuellement recommandé. Une fonctionnalité de visualisation Grad-CAM a par ailleurs été intégrée afin de rendre interprétable la décision du réseau pour le praticien. Les limites du système, notamment la fiabilité statistique réduite de la classe bénigne et l'absence de vérification de la nature réelle de l'image soumise, sont enfin discutées, ouvrant la voie à des perspectives d'amélioration.

TABLE DES MATIÈRES

CHAPITRE 1 : INTRODUCTION GÉNÉRALE	3
1.1. Contexte.....	3
1.2. Problématique	3
1.3. Objectifs	4
1.3.1. Objectif général	4
1.3.2. Objectifs spécifiques.....	4
1.4. Méthodologie adoptée	4
1.5. Structure du document.....	5
CHAPITRE 2 : CADRE THÉORIQUE ET TECHNOLOGIQUE	5
2.1. Définition des concepts clés	5
2.1.1. Intelligence artificielle et apprentissage profond.....	5
2.1.2. Réseau de neurones convolutif (CNN).....	5
2.1.3. Grad-CAM.....	5
2.1.4. Programmation orientée objet (POO).....	6
2.1.5. Architecture logicielle en couches.....	6
2.1.6. Interface de programmation applicative (API) REST	6
2.2. Présentation des outils et technologies utilisés.....	6
2.2.1. Python et l'écosystème d'apprentissage profond.....	6
2.2.2. Flask	7
2.2.3. PHP orienté objet et MySQL.....	7
2.2.4. Technologies front-end.....	7
2.2.5. Outils de gestion de version et d'environnement.....	7
CHAPITRE 3 : RÉALISATION DU PROJET	8
3.1. Analyse des besoins.....	8
3.1.1. Besoins fonctionnels.....	8

3.1.2. Besoins non fonctionnels.....	8
3.2. Architecture de la solution.....	8
3.3. Étapes de mise en œuvre	9
3.3.1. Constitution et fusion du jeu de données.....	9
3.3.2. Prétraitement des images	9
3.3.3. Conception modulaire de l'architecture CNN.....	9
3.3.4. Entraînement du modèle	10
3.3.5. Développement du back-end orienté objet	10
3.3.6. Intégration Grad-CAM	10
3.4. Résultats obtenus	10
CHAPITRE 4 : DIFFICULTÉS RENCONTRÉES ET LIMITES.....	11
4.1. Difficultés rencontrées.....	11
4.1.1. Difficultés d'ordre technique	11
4.1.2. Insuffisance des données d'entraînement pour la classe bénigne	11
4.1.3. Difficultés d'ordre organisationnel	12
4.2. Limites de la solution	12
CHAPITRE 5 : CONCLUSION GÉNÉRALE	13
5.1. Récapitulatif	13
5.2. Apports du projet.....	13
5.3. Perspectives	13
BIBLIOGRAPHIE ET WEBOGRAPHIE.....	14
I. Ouvrages méthodologiques	14
II. Intelligence artificielle et apprentissage profond.....	14
III. Traitement d'images et imagerie médicale	15
IV. Génie logiciel et programmation orientée objet.....	15
V. Rapports et documents officiels	15
Webographie.....	16

ANNEXES	16
Annexe 1 : Dépôt du code source	17
Annexe 2 : Captures d'écran des interfaces utilisateur	17
Annexe 3 : Modélisation de la base de données	17

CHAPITRE 1 : INTRODUCTION GÉNÉRALE

1.1. Contexte

Le cancer du poumon constitue, à l'échelle mondiale, l'une des premières causes de mortalité par cancer, en raison notamment de la découverte tardive de la maladie à des stades où les options thérapeutiques sont réduites. Le diagnostic repose classiquement sur la lecture, par un radiologue, d'images de tomodensitométrie (CT Scan) thoracique, un exercice exigeant, chronophage et soumis à la variabilité inter-observateur inhérente à toute expertise humaine.

Parallèlement, les progrès de l'intelligence artificielle, et en particulier de l'apprentissage profond fondé sur les réseaux de neurones convolutifs (Convolutional Neural Networks, CNN), ont démontré leur capacité à extraire automatiquement, à partir d'images médicales, des motifs visuels pertinents pour la classification de pathologies. Ces techniques, popularisées notamment par les travaux de Yann LeCun sur la reconnaissance visuelle, ouvrent la voie à des systèmes d'aide au diagnostic capables de soutenir le praticien sans se substituer à lui.

C'est dans cette perspective que s'inscrit le projet PulmoCare IA, une plateforme conçue pour les professionnels de santé, qui associe un module d'intelligence artificielle de classification d'images CT Scan à une application web complète de gestion des dossiers d'analyse, destinée à un usage hospitalier.

1.2. Problématique

Le diagnostic du cancer du poumon à partir d'images CT Scan présente plusieurs difficultés pratiques. D'une part, l'analyse visuelle par un radiologue demeure longue et sujette à une charge de travail importante compte tenu du volume croissant d'examens réalisés. D'autre part, les outils numériques existants dans les établissements de santé de la région ne proposent généralement pas de module d'aide automatisée à la détection, encore moins d'outils rendant la décision du modèle interprétable pour le clinicien.

Le problème fondamental que ce travail tente de résoudre peut donc se formuler ainsi : comment concevoir une plateforme numérique intégrant un modèle d'intelligence artificielle fiable de classification d'images CT Scan pulmonaires, exploitable par un médecin dans un cadre

professionnel, tout en respectant les exigences de sensibilité médicale, de traçabilité et d'interprétabilité propres au domaine de la santé ?

Cette problématique soulève plusieurs questions subsidiaires : quelle architecture de réseau de neurones convolutif permet d'obtenir une sensibilité suffisante sur la classe maligne, laquelle est la plus critique sur le plan clinique ? Comment gérer le déséquilibre des classes lorsque les cas non cancéreux sont sous-représentés dans les données disponibles ? Quelle architecture logicielle back-end permet d'assurer une communication fiable entre l'interface médicale et le modèle d'intelligence artificielle ?

1.3. Objectifs

1.3.1. Objectif général

L'objectif général de ce travail est de concevoir et d'implémenter une plateforme intelligente d'aide au diagnostic du cancer du poumon, structurée autour d'un modèle CNN modulaire, d'un back-end orienté objet et d'une interface professionnelle destinée aux médecins.

1.3.2. Objectifs spécifiques

- Constituer un jeu de données équilibré en fusionnant plusieurs sources afin de disposer des trois classes cliniques nécessaires (normal, bénin, malin) ;
- Concevoir une architecture de réseau de neurones convolutif paramétrable et modulaire, permettant de faire varier le nombre de blocs convolutifs et de couches denses ;
- Entraîner et évaluer ce modèle selon des métriques adaptées au contexte médical, en particulier la sensibilité sur la classe maligne ;
- Développer un back-end orienté objet en PHP assurant la communication sécurisée entre l'interface utilisateur et le service d'intelligence artificielle ;
- Intégrer une visualisation Grad-CAM afin de rendre interprétable la décision du modèle pour le praticien ;
- Concevoir une interface utilisateur sobre et professionnelle, adaptée à un usage médical et non à une simple démonstration technologique.

1.4. Méthodologie adoptée

La démarche suivie a combiné plusieurs méthodes complémentaires. La méthode documentaire a permis de dégager, à partir de la littérature existante, les bonnes pratiques de conception d'un système de classification d'images médicales par apprentissage profond. La méthode expérimentale a ensuite été appliquée lors de la phase d'entraînement du modèle, à travers l'observation systématique de l'effet des choix architecturaux et des hyper paramètres sur les métriques de performance.

Sur le plan technique, le travail s'est déroulé en plusieurs étapes successives : analyse du besoin médical, récoltes de données, fusion et préparation des données, conception modulaire du modèle CNN, entraînement et évaluation, développement du back-end orienté objet, développement de l'interface front-end, puis intégration et tests de bout en bout entre les trois couches applicatives.

1.5. Structure du document

Ce document est structuré en cinq chapitres. Le premier chapitre, Introduction générale, présente le contexte, la problématique, les objectifs et la méthodologie du travail. Le deuxième chapitre, Cadre théorique et technologique, définit les concepts clés mobilisés et présente les outils et technologies utilisés. Le troisième chapitre, Réalisation du projet, expose l'analyse des besoins, l'architecture retenue, les étapes de mise en œuvre ainsi que les résultats obtenus. Le quatrième chapitre, Difficultés rencontrées et limites, discute des obstacles rencontrés et des limites actuelles du système. Enfin, le cinquième chapitre, Conclusion générale, récapitule le travail effectué, en présente les apports et propose des perspectives d'évolution.

CHAPITRE 2 : CADRE THÉORIQUE ET TECHNOLOGIQUE

2.1. Définition des concepts clés

2.1.1. Intelligence artificielle et apprentissage profond

L'intelligence artificielle désigne l'ensemble des techniques permettant à un système informatique de réaliser des tâches associées à l'intelligence humaine, telles que la reconnaissance de motifs visuels. L'apprentissage profond (deep learning) en est une branche fondée sur des réseaux de neurones artificiels comportant plusieurs couches de traitement successives, chacune extrayant des représentations de plus en plus abstraites des données d'entrée.

2.1.2. Réseau de neurones convolutif (CNN)

Un réseau de neurones convolutif est une architecture d'apprentissage profond particulièrement adaptée au traitement d'images. Il repose sur l'alternance de couches de convolution, qui appliquent des filtres appris automatiquement pour détecter des motifs locaux (contours, textures, formes), et de couches de pooling, qui réduisent la dimension spatiale tout en conservant l'information la plus pertinente. Dans PulmoCare IA, chaque bloc convolutif associe une convolution, une normalisation par lots (batch normalization), une fonction d'activation ReLU et un sous-échantillonnage par max-pooling, avant que les caractéristiques extraites ne soient transmises à des couches entièrement connectées assurant la classification finale.

2.1.3. Grad-CAM

Le Gradient-weighted Class Activation Mapping (Grad-CAM) est une technique d'interprétabilité qui permet de visualiser, sous forme de carte thermique superposée à l'image d'origine, les régions ayant le plus contribué à la décision du réseau pour une classe donnée. Cette technique est essentielle en contexte médical car elle permet au praticien de vérifier que le modèle fonde sa décision sur des zones anatomiquement pertinentes et non sur des artefacts de l'image.

2.1.4. Programmation orientée objet (POO)

La programmation orientée objet est un paradigme de programmation structurant le code autour d'entités appelées classes, encapsulant à la fois des données (attributs) et des comportements (méthodes). Ce paradigme favorise la réutilisabilité, la maintenabilité et la clarté du code, par opposition à une programmation procédurale linéaire. Le back-end de PulmoCare IA applique ce paradigme à travers des classes telles que Database, SessionManager, User, Detection, Security ou Validator, chacune ayant une responsabilité unique.

2.1.5. Architecture logicielle en couches

Une architecture en couches organise une application en niveaux de responsabilité distincts, typiquement une couche de présentation, une couche métier et une couche d'accès aux données. Cette organisation limite les dépendances croisées et facilite l'évolution indépendante de chaque couche. PulmoCare IA applique ce principe à travers la séparation entre les modèles (Models), les contrôleurs (Controllers), les fonctions utilitaires centralisées et la couche de présentation.

2.1.6. Interface de programmation applicative (API) REST

Une API REST est une interface exposant des ressources via le protocole HTTP, permettant à des systèmes hétérogènes de communiquer selon un format standard, généralement JSON. Dans PulmoCare IA, le microservice Python expose une API REST (routes /predict, /predict/gradcam, /health) consommée par le back-end PHP, ce qui découple le cycle de vie du modèle d'intelligence artificielle de celui de l'application web.

2.2. Présentation des outils et technologies utilisés

2.2.1. Python et l'écosystème d'apprentissage profond

Python a été retenu pour le module d'intelligence artificielle en raison de la maturité de son écosystème scientifique. TensorFlow et son interface Keras assurent la construction, la compilation et l'entraînement du réseau CNN. La bibliothèque OpenCV (cv2) prend en charge le prétraitement des images (redimensionnement, amélioration du contraste par CLAHE, réduction du bruit par filtre gaussien), tandis que scikit-learn fournit les métriques d'évaluation

(précision, rappel, F1-score, aire sous la courbe ROC) ainsi que le calcul automatique des poids de classes destinés à compenser le déséquilibre du jeu de données.

2.2.2. *Flask*

Flask est un micro-framework Python léger utilisé pour exposer le modèle entraîné sous forme de service web. Il permet de charger le modèle une seule fois en mémoire au démarrage du serveur, puis de traiter chaque requête de prédiction sans recharger le modèle, ce qui optimise nettement les temps de réponse par rapport à un appel du script Python via exécution système (exec) à chaque requête.

2.2.3. *PHP orienté objet et MySQL*

Le back-end de la plateforme est développé en PHP 8.2, en s'appuyant exclusivement sur la programmation orientée objet : gestion de la base de données via PDO au sein d'une classe Database appliquant le patron de conception singleton, gestion sécurisée des sessions via une classe SessionManager (protection contre la fixation de session, empreinte de session, jetons CSRF), et modèles de données héritant d'une classe abstraite BaseModel factorisant les opérations CRUD. La base de données relationnelle MySQL assure la persistance des utilisateurs, des hôpitaux et des détections.

2.2.4. *Technologies front-end*

L'interface utilisateur repose sur HTML5, CSS3 et JavaScript natif, complétés par la bibliothèque Chart.js pour la visualisation graphique des statistiques (répartition des résultats, évolution mensuelle des analyses) et par Font Awesome pour l'iconographie. Le choix a été fait de ne pas recourir à un framework front-end lourd, afin de conserver un contrôle fin sur la sobriété et la lisibilité de l'interface, jugées prioritaires dans un contexte d'usage médical professionnel.

2.2.5. *Outils de gestion de version et d'environnement*

Le contrôle de version du code source est assuré par Git et hébergé sur GitHub. L'environnement de développement local repose sur XAMPP pour la partie PHP et MySQL, tandis que l'entraînement du modèle CNN a été réalisé sur Google Colab, bénéficiant d'une accélération matérielle GPU (T4) non disponible en environnement local.

CHAPITRE 3 : RÉALISATION DU PROJET

3.1. Analyse des besoins

L'analyse du besoin a été conduite en considérant l'utilisateur final comme un professionnel de santé (médecin radiologue, pneumologue, oncologue) et non comme un public technophile. Il en résulte des besoins fonctionnels et non fonctionnels distincts.

3.1.1. Besoins fonctionnels

- Authentification sécurisée du médecin, rattachée à un établissement hospitalier ;
- Téléversement d'une image CT Scan accompagnée des informations administratives du patient ;
- Classification automatique de l'image en trois catégories : normal, bénin, malin ;
- Enrichissement du résultat brut par un stade TNM estimé, un type histologique probable et des recommandations cliniques ;
- Visualisation Grad-CAM de la zone suspecte lorsque celle-ci est demandée ;
- Historique, recherche multicritères et export du rapport d'analyse ;
- Tableau de bord statistique de l'activité du médecin.

3.1.2. Besoins non fonctionnels

- Sensibilité élevée sur la classe maligne, priorité absolue en contexte médical ;
- Séparation claire entre le service d'intelligence artificielle et l'application web ;
- Sécurité des données (jetons CSRF, hachage des mots de passe, limitation de débit) ;
- Interface sobre, professionnelle, dépourvue de toute référence technique visible pour l'utilisateur médecin.

3.2. Architecture de la solution

La plateforme PulmoCare IA repose sur une architecture à trois niveaux. Le premier niveau, front-end, est constitué des pages HTML/CSS/JavaScript consommées par le navigateur du médecin. Le deuxième niveau, back-end, est développé en PHP orienté objet et assure

l'authentification, la validation, la persistance en base de données et l'orchestration des appels vers le module d'intelligence artificielle. Le troisième niveau, service d'intelligence artificielle, est un microservice Flask, écrit en Python, exposant le modèle CNN entraîné via une API REST dédiée.

La communication entre le back-end PHP et le service Flask s'effectue par requête HTTP multipart, le PHP transmettant l'image téléversée et récupérant en retour un rapport JSON structuré en deux niveaux : un niveau brut, correspondant directement à la sortie du CNN, et un niveau enrichi, correspondant au diagnostic médical élargi (stade, type histologique, recommandations).

Le schéma de la base de données relationnelle ainsi que le modèle logique de données sont présentés à l'Annexe 3 du présent document.

3.3. Étapes de mise en œuvre

3.3.1. Constitution et fusion du jeu de données

Le jeu de données initial, issu de la plateforme Roboflow, ne comportait que des cas cancéreux (NSCLC et SCLC), rendant impossible l'apprentissage des classes normale et bénigne. Ce jeu a donc été fusionné avec le jeu de données IQ-OTH/NCCD, qui apporte les cas normaux et bénins manquants. Après suppression des doublons, le corpus final comptait 7 918 images réparties de manière déséquilibrée entre les trois classes, la classe maligne représentant à elle seule plus de 93 pour cent des observations.

Ce déséquilibre a été traité par le calcul automatique de poids de classe selon la méthode dite « balanced », attribuant un poids nettement supérieur aux classes minoritaires (normal et bénin) afin que le modèle leur accorde une importance proportionnellement plus grande lors de l'entraînement.

3.3.2. Prétraitement des images

Chaque image est redimensionnée à 224 par 224 pixels avec conservation du rapport d'aspect par remplissage, normalisée dans l'intervalle 0 à 1, puis, lors de la phase de prédiction, soumise à une amélioration de contraste par égalisation adaptative d'histogramme (CLAHE) et à une

réduction du bruit par filtre gaussien, ces deux dernières opérations étant particulièrement adaptées à l'imagerie médicale de type CT Scan.

3.3.3. Conception modulaire de l'architecture CNN

Le modèle a été conçu selon une logique modulaire, chaque bloc convolutif étant paramétré par un triplet (nombre de filtres, taille du noyau, pas de convolution), et chaque couche dense étant paramétrée par un couple (nombre de neurones, taux de dropout). Cette approche permet de faire varier l'architecture sans modifier le code source, par simple changement de la configuration transmise au constructeur du modèle. L'architecture retenue pour l'expérience de référence comporte quatre blocs convolutifs (32, 64, 128 puis 256 filtres) suivis de deux couches denses (512 puis 256 neurones).

3.3.4. Entraînement du modèle

L'entraînement a été mené sur cinquante époques au maximum, avec arrêt anticipé (early stopping) surveillant l'exactitude de validation, réduction automatique du taux d'apprentissage sur plateau, et sauvegarde systématique du meilleur point de contrôle. Le meilleur modèle a été obtenu à la huitième époque, avant que l'arrêt anticipé n'interrompe l'entraînement à la dix-huitième époque faute d'amélioration supplémentaire.

3.3.5. Développement du back-end orienté objet

Le back-end a été structuré autour de modèles orientés objet (User, Detection, Hospital) héritant d'une classe abstraite commune, de contrôleurs dédiés (DetectionController, AuthController, UserController) et d'une bibliothèque de fonctions centralisées assurant l'authentification, la validation des données, la sécurité et la communication avec le service d'intelligence artificielle.

3.3.6. Intégration Grad-CAM

La fonctionnalité Grad-CAM, déjà pleinement implémentée côté Python, a été raccordée à l'interface via un second point d'entrée de l'API Flask dédié (/predict/gradcam), retournant à la fois le rapport de diagnostic et l'image de superposition encodée en base64, directement exploitable par le navigateur sans fichier intermédiaire.

3.4. Résultats obtenus

L'évaluation finale du modèle sur le jeu de test, comportant 792 images, a produit les résultats synthétisés dans le tableau ci-dessous.

Métrique	Valeur
Exactitude globale (accuracy)	95,83 %
Sensibilité classe maligne	98,78 %
Spécificité classe maligne	66,67 %
Précision classe maligne	97,59 %
Aire sous la courbe ROC (macro)	0,974
Faux négatifs (cancers non détectés)	9 sur 738

Ces résultats satisfont le seuil médical usuellement retenu, à savoir une sensibilité supérieure ou égale à 90 pour cent sur la classe maligne, la conséquence clinique d'un faux négatif (cancer non détecté) étant nettement plus grave que celle d'un faux positif. La classe bénigne, en revanche, ne repose que sur douze images de test, ce qui limite fortement la portée statistique des métriques la concernant et invite à la prudence dans leur interprétation.

CHAPITRE 4 : DIFFICULTÉS RENCONTRÉES ET LIMITES

4.1. Difficultés rencontrées

4.1.1. Difficultés d'ordre technique

La principale difficulté technique a résidé dans le déséquilibre structurel du jeu de données, la classe maligne représentant plus de 93 pour cent des observations après fusion des deux sources. Ce déséquilibre a nécessité la mise en place d'une pondération automatique des classes ainsi qu'une réflexion sur l'augmentation ciblée des classes minoritaires.

Une seconde difficulté technique a concerné l'incohérence de prétraitement entre l'entraînement et la prédiction (train-serving skew) : le pipeline d'entraînement n'appliquait qu'un redimensionnement et une normalisation simples, tandis que le pipeline de prédiction appliquait en sus une amélioration de contraste CLAHE et une réduction de bruit gaussien. Une telle divergence, si elle n'est pas corrigée, peut dégrader la fiabilité du modèle en production, en particulier pour les classes déjà fragiles statistiquement.

Une troisième difficulté a résidé dans le diagnostic d'anomalies d'affichage côté interface web, notamment une condition de compétition JavaScript où le formulaire était soumis avant que la lecture asynchrone du fichier image (FileReader) ne soit achevée, ainsi qu'un oubli de persistance du champ avatar dans la gestion de session PHP.

4.1.2. Insuffisance des données d'entraînement pour la classe bénigne

Une difficulté majeure, distincte du déséquilibre global déjà évoqué, concerne spécifiquement la rareté des cas bénins disponibles dans les sources publiques exploitées. Après fusion et déduplication, la classe bénigne ne représente que 120 images sur un total de 7 918, soit environ 1,5 pour cent du corpus, contre 5,3 pour cent pour la classe normale et 93,2 pour cent pour la classe maligne. Une fois répartie selon le schéma de découpage retenu (70 pour cent entraînement, 20 pour cent validation, 10 pour cent test), cette classe ne compte plus que 84 images pour l'entraînement, 24 pour la validation et 12 seulement pour le test.

Les conséquences de cette rareté sur le comportement du modèle sont multiples. D'une part, le réseau dispose de trop peu d'exemples pour apprendre une représentation robuste et généralisable des nodules bénins, ce qui explique la précision et le rappel nettement plus faibles

obtenus sur cette classe lors de l'évaluation finale, comparativement à la classe maligne. D'autre part, l'échantillon de test étant réduit à douze images, toute métrique calculée sur cette classe (précision, rappel, F1-score) est statistiquement fragile : une seule image mal classée y fait varier le résultat de plusieurs points de pourcentage, ce qui interdit toute conclusion définitive quant à la fiabilité réelle du modèle sur les cas bénins. Enfin, cette faiblesse fait peser un risque clinique spécifique, à savoir la confusion possible entre un nodule bénin et une lésion maligne ou, à l'inverse, entre un nodule bénin et un poumon normal, deux erreurs aux conséquences médicales très différentes.

Face à ce problème, plusieurs mesures ont déjà été engagées ou sont envisagées. Un mécanisme de pondération automatique des classes (class weight) a été mis en place afin que les erreurs commises sur la classe bénigne pèsent proportionnellement plus lourd dans la fonction de perte durant l'entraînement. Une routine d'augmentation ciblée des classes minoritaires a également été développée, appliquant des transformations géométriques et photométriques (rotation, retournement, zoom, variation de luminosité) exclusivement aux images d'entraînement des classes sous-représentées, afin d'en multiplier artificiellement la diversité sans jamais toucher aux ensembles de validation et de test. À plus long terme, la solution la plus déterminante consistera à enrichir le corpus par la recherche et l'intégration de nouvelles sources de données publiques ou hospitalières spécifiquement dédiées aux nodules bénins, éventuellement complétée par une stratégie de transfert d'apprentissage (transfer learning) à partir de modèles pré-entraînés sur de plus vastes bases d'imagerie médicale, afin de réduire la dépendance du modèle à la seule quantité de données bénignes disponibles localement.

4.1.3. Difficultés d'ordre organisationnel

Le temps d'entraînement du modèle sur un environnement local dépourvu d'accélération matérielle GPU s'est révélé prohibitif, ce qui a conduit à migrer cette étape vers Google Colab. La synchronisation entre le dépôt de code source et l'environnement d'entraînement distant a par ailleurs exigé une organisation rigoureuse du flux de travail.

4.2. Limites de la solution

- La classe bénigne repose sur un échantillon de test trop restreint (douze images) pour que ses métriques soient statistiquement fiables ;

- Le système ne vérifie pas que l'image soumise est effectivement une image de scanner thoracique : toute image téléversée par l'utilisateur est traitée et classée par le modèle, même si elle ne représente pas un examen CT Scan pulmonaire, cette fonctionnalité de vérification n'ayant pas été implémentée dans la version actuelle ;
- L'incohérence de prétraitement entre entraînement et prédiction, identifiée au chapitre précédent, n'a pas encore été définitivement corrigée à ce stade du projet ;
- Le stade TNM et le type histologique proposés par le système demeurent des estimations algorithmiques fondées sur des règles heuristiques, et ne remplacent en aucun cas une confirmation histopathologique ;
- Le système n'a pas encore fait l'objet d'une validation clinique prospective auprès de praticiens en conditions réelles d'exercice.

CHAPITRE 5 : CONCLUSION GÉNÉRALE

5.1. Récapitulatif

Cette monographie a présenté la conception et l'implémentation de PulmoCare IA, une plateforme d'aide au diagnostic du cancer du poumon destiné aux professionnels de santé. Le travail a consisté à fusionner deux jeux de données complémentaires pour disposer des trois classes cliniques nécessaires, à concevoir une architecture CNN modulaire et paramétrable inspirée d'une logique de programmation par blocs de configuration, à entraîner ce modèle en tenant compte du déséquilibre des classes, puis à l'intégrer dans une application web structurée selon un back-end orienté objet en PHP et un service d'intelligence artificielle exposé en Python via Flask.

5.2. Apports du projet

Sur le plan méthodologique, ce projet a permis de mobiliser concrètement les principes de la programmation orientée objet, de la programmation modulaire appliquée à un modèle d'apprentissage profond, ainsi que les bonnes pratiques d'architecture logicielle en couches. Sur le plan médical, la plateforme illustre comment un système d'intelligence artificielle peut être conçu non comme un outil de remplacement du médecin, mais comme un instrument d'aide à la décision, dont la sensibilité sur la classe la plus critique satisfait les exigences usuelles du domaine, et dont la décision peut être rendue interprétable grâce à la visualisation Grad-CAM.

5.3. Perspectives

- Corriger définitivement l'incohérence de prétraitement entre l'entraînement et la prédiction, en harmonisant les deux pipelines ;
- Enrichir le jeu de données, en particulier pour la classe bénigne, afin de disposer de métriques statistiquement fiables ;
- Ajouter une nouvelle fonctionnalité de reconnaissance préalable de la nature de l'image soumise : dans l'état actuel du système, si un utilisateur téléverse une photographie quelconque, qui n'est pas une image de scanner thoracique, le système l'analyse tout de même et produit une classification, faute d'avoir été conçu pour ce type de vérification. Une perspective majeure consiste donc à implémenter un module de validation préalable

capable de détecter qu'une image soumise n'est pas une image médicale CT Scan pulmonaire, et de rejeter une telle image avant toute tentative de classification cancéreuse.

- Mener une phase de validation clinique du modèle auprès de praticiens en conditions réelles d'exercice ;
- Étendre la plateforme à d'autres modalités d'imagerie et à d'autres pathologies pulmonaires.

Ce travail confirme ainsi qu'une solution d'intelligence artificielle, même conçue dans un cadre académique, peut atteindre un niveau de rigueur méthodologique et de performance compatible avec les exigences du domaine médical, tout en ouvrant des perspectives concrètes d'amélioration continue.

BIBLIOGRAPHIE ET WEBOGRAPHIE

I. Ouvrages méthodologiques

FACULTÉ DES SCIENCES INFORMATIQUES (FASI), Initiation à la recherche scientifique, Notes de cours à l'intention des étudiants de deuxième graduat, Kinshasa, FASI, 2024, 45 p.

N'DA, P., Méthodologie de la recherche : de la problématique à la discussion des résultats, Abidjan, Éduci, 2015, 218 p.

II. Intelligence artificielle et apprentissage profond

GOODFELLOW, I., BENGIO, Y. et COURVILLE, A., Deep Learning, Cambridge, MIT Press, 2016, 800 p.

CHOLLET, F., Deep Learning with Python, 2e éd., Shelter Island, Manning Publications, 2021, 504 p.

KRIZHEVSKY, A., SUTSKEVER, I. et HINTON, G., « ImageNet Classification with Deep Convolutional Neural Networks », in Advances in Neural Information Processing Systems, vol. 25, 2012, pp. 1097–1105.

SELVARAJU, R. R., COGSWELL, M., DAS, A., VEDANTAM, R., PARIKH, D. et BATRA, D., « Grad-CAM : Visual Explanations from Deep Networks via Gradient-based Localization », in Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 618–626.

IOFFE, S. et SZEGEDY, C., « Batch Normalization : Accelerating Deep Network Training by Reducing Internal Covariate Shift », in Proceedings of the 32nd International Conference on Machine Learning, 2015, pp. 448–456.

SRIVASTAVA, N., HINTON, G., KRIZHEVSKY, A., SUTSKEVER, I. et SALAKHUTDINOV, R., « Dropout : A Simple Way to Prevent Neural Networks from Overfitting », in Journal of Machine Learning Research, vol. 15, 2014, pp. 1929–1958.

III. Traitement d'images et imagerie médicale

GONZALEZ, R. C. et WOODS, R. E., Digital Image Processing, 4e éd., New York, Pearson, 2018, 1168 p.

BRADSKI, G. et KAEHLER, A., Learning OpenCV : Computer Vision with the OpenCV Library, Sebastopol, O'Reilly Media, 2008, 580 p.

ZUIDERVELD, K., « Contrast Limited Adaptive Histogram Equalization », in HECKBERT, P. (dir.), Graphics Gems IV, San Diego, Academic Press, 1994, pp. 474–485.

IV. Génie logiciel et programmation orientée objet

ZANDSTRA, M., PHP Objects, Patterns, and Practice, 6e éd., Berkeley, Apress, 2019, 620 p.

GAMMA, E., HELM, R., JOHNSON, R. et VLISSIDES, J., Design Patterns : Elements of Reusable Object-Oriented Software, Boston, Addison-Wesley, 1994, 395 p.

SOMMERVILLE, I., Software Engineering, 10e éd., Harlow, Pearson, 2016, 816 p.

V. Rapports et documents officiels

ORGANISATION MONDIALE DE LA SANTÉ (OMS), Rapport mondial sur le cancer, Genève, OMS, 2024.

CENTRE INTERNATIONAL DE RECHERCHE SUR LE CANCER (CIRC/IARC), GLOBOCAN : Estimations mondiales de l'incidence et de la mortalité par cancer, Lyon, IARC, 2022.

Webographie

TENSORFLOW, « Documentation officielle », <https://www.tensorflow.org>, consulté le 10 juillet 2026.

KERAS, « Keras API reference », <https://keras.io/api>, consulté le 10 juillet 2026.

FLASK, « Documentation officielle du framework Flask », <https://flask.palletsprojects.com>, consulté le 10 juillet 2026.

PHP, « Manuel officiel du langage PHP », <https://www.php.net/manual/fr>, consulté le 10 juillet 2026.

OPENCV, « OpenCV-Python Tutorials », <https://docs.opencv.org>, consulté le 10 juillet 2026.

KAGGLE, « The IQ-OTH/NCCD Lung Cancer Dataset », <https://www.kaggle.com/datasets/hamdallak/the-iqothnccd-lung-cancer-dataset>, consulté le 2 juin 2026.

ROBOFLOW, « Plateforme de gestion et d'annotation de jeux de données d'images », <https://roboflow.com>, consulté le 2 juin 2026.

CHART.JS, « Documentation officielle », <https://www.chartjs.org/docs>, consulté le 10 juillet 2026.

ANNEXES


Les annexes suivantes complètent le présent document. Pour des raisons de format, les éléments visuels (captures d'écran et diagrammes) sont à insérer aux emplacements indiqués ci-dessous.

Annexe 1 : Dépôt du code source

L'intégralité du code source du projet PulmoCare IA (module d'intelligence artificielle Python, back-end PHP orienté objet, interface front-end) est disponible sur le dépôt GitHub suivant :


<https://github.com/raddai101/pulmocare>

Annexe 2 : Captures d'écran des interfaces utilisateur



Annexe 3 : Modélisation de la base de données

1.MCD



2. MLD

